

GUIA DE MESTRIA PARA A DEFESA DE TCC

Mecanismo Kanban IA

*Otimização operacional via injeção semântica de IA
e controle de acesso por TAGS (RLS)*

Como usar este documento:

Leia os capítulos 1 a 4 nos dias **D-7 a D-3** antes da banca.

Decore os números do **cartão de bolso** (cap. 8) na **véspera**.

Releia o cap. 6 (perguntas) e o cap. 7 (armadilhas) **na manhã** da defesa.

Objetivo: chegar na banca podendo defender qualquer ponto do trabalho sem consulta.

Vinicius Vilela Rufini

UNIP - Ciência da Computação - 2026

Sumário

1. Resumo executivo (sua tese em 60 segundos)	3
2. Glossário técnico — todos os termos que você cita	4
3. Os 5 conceitos que você TEM que dominar	6
4. Arquitetura do sistema explicada em camadas	10
5. Roteiro narrativo da defesa (fala slide a slide)	12
6. 30 perguntas prováveis da banca + respostas modelo	15
7. Armadilhas da banca e como escapar delas	21
8. Cartão de bolso — números e fatos para decorar	23
9. Checklist do dia D	24

1. Resumo executivo — sua tese em 60 segundos

Se a banca te perguntar logo de cara “em poucas palavras, o que é o seu trabalho?”, esta é a resposta que você deve ter memorizada — e que cabe em **1 minuto** de fala.

Problema: Equipes corporativas que usam Kanban tradicional perdem entre 15% e 30% do tempo procurando POPs e regras de negócio — o *Gargalo Cognitivo* — o que gera quebras de SLA e baixa resolução no primeiro contato.

Hipótese: Se um LLM puder injetar, dentro do próprio cartão Kanban, um checklist filtrado por TAGS temáticas autorizadas via Row Level Security, então o Wait Time despenca e o Cycle Time cai junto.

Método: Simulação Computacional de Eventos Discretos em Node.js, replicada 30 vezes via Monte Carlo em Python, com teste t pareado bilateral ($df=29$, $\alpha=0,001$).

Resultados: Cycle Time -44,6% ($p<0,001$), Quebra de SLA cai de 28,3% para 0%, FCR sobe de 53,4% para 95,3%, consumo de tokens do LLM -87,5%.

Contribuição: Não é mais um chatbot lateral — é a transformação do cartão Kanban em um *agente contextual semântico*, com isolamento multilocatário garantido pelo núcleo do PostgreSQL.

Frase de impacto para abrir a defesa

“O Kanban tradicional dá visibilidade ao fluxo. O Kanban IA dá visibilidade ao fluxo e injeta, no próprio cartão, o conhecimento corporativo que faz a tarefa andar — sob isolamento multilocatário absoluto.”

2. Glossário técnico

Se você travar em qualquer um destes termos durante a arguição, vai parecer que decorou em vez de entender. Saiba explicar cada um **em 1 frase, sem ler**.

Kanban — Método de gestão visual herdado do Sistema Toyota de Produção, formalizado por Anderson (2010), baseado em 4 práticas: visualizar o fluxo, limitar o WIP, gerenciar o fluxo e tornar as políticas explícitas.

WIP (Work in Progress) — Quantidade de cartões em execução simultânea. Limitar o WIP é o que faz o Kanban funcionar — quando há excesso de trabalho parado, o sistema sinaliza visualmente.

Lead Time — Tempo entre a entrada da demanda no sistema e a entrega final ao solicitante. Inclui tempo em fila.

Cycle Time — Tempo em que o cartão fica na coluna 'In Progress'. Soma de Wait Time + Touch Time. É a métrica central do seu trabalho.

Wait Time — Tempo gasto pelo operador esperando alguma coisa: consulta a manual, resposta de supervisor, busca em planilha. É o tempo invisível e a sua grande vítima.

Touch Time — Tempo de execução técnica efetiva do trabalho — quando as mãos estão na tarefa.

Throughput — Quantidade de cartões concluídos por unidade de tempo.

Gargalo Cognitivo — Termo cunhado por você no TCC. Designa o tempo invisível gasto pelo operador na busca por conhecimento operacional. É a manifestação prática do Wait Time.

SLA (Service Level Agreement) — Acordo contratual de nível de serviço. No seu TCC, fixado em 240 minutos (4 horas).

FCR (First Contact Resolution) — Percentual de chamados resolvidos sem escalção para níveis hierárquicos superiores.

LLM (Large Language Model) — Modelos de linguagem de grande escala (Gemini, GPT, Claude...). Funcionam recebendo um *prompt* e devolvendo texto preditivo.

Token — Unidade mínima de processamento do LLM — fragmento de palavra. Cada chamada à API é cobrada por tokens consumidos.

Prompt — Entrada textual enviada ao LLM. No seu sistema, o prompt é montado dinamicamente com os metadados do cartão + POPs filtrados.

Alucinação — Quando o LLM inventa fatos ou regras inexistentes. O RAG e o filtro por TAGS minimizam isso.

RAG (Retrieval-Augmented Generation) — Arquitetura introduzida por Lewis et al. (2020): o LLM não responde só com o que aprendeu — antes da geração, busca-se conhecimento externo relevante e injeta-se no prompt.

TAGS de Autorização Temática — Termo seu. Etiquetas semânticas (ex: [SLA_FINANCEIRO], [TURNO_NOTURNO]) que classificam tanto cartões quanto registros da knowledge_base, permitindo o casamento e a filtragem cirúrgica antes do LLM.

Mecanismo de Scoping Temático Autônomo — O coração da sua contribuição. É o processo de 4 etapas: (1) clique do operador, (2) envio de metadados + JWT, (3) consulta filtrada por TAG sob RLS, (4) prompt enxuto ao Gemini.

RLS (Row Level Security) — Política nativa do PostgreSQL que filtra *quais linhas* uma consulta pode ver, antes mesmo de avaliar a cláusula WHERE explícita. Aplicada com CREATE POLICY.

Multilocatário (multi-tenant) — Arquitetura SaaS em que múltiplos clientes (tenants) compartilham a mesma infraestrutura, mas seus dados ficam logicamente isolados. Você usa company_id + RLS.

SPA (Single Page Application) — Aplicação web que carrega uma única página HTML e atualiza o conteúdo dinamicamente via JavaScript. Padrão do seu frontend React + Vite.

BaaS (Backend as a Service) — Backend completo entregue como serviço (banco + auth + API). O Supabase é o seu BaaS.

Vercel Edge Network — CDN/serverless da Vercel que distribui sua SPA mundialmente com baixa latência. Suporta rewrites first-party.

Rewrites first-party — Regras de roteamento que fazem chamadas a APIs externas parecerem vir do seu próprio domínio, contornando bloqueadores de anúncios e CORS.

DES (Discrete-Event Simulation) — Modelagem de sistemas como uma sequência de eventos discretos no tempo. Referência: Banks et al. (2010).

Monte Carlo — Técnica de simulação estocástica que executa o experimento múltiplas vezes para obter uma distribuição de resultados — você fez 30 réplicas.

Teste t pareado — Teste estatístico inferencial para comparar duas medidas tomadas do mesmo conjunto de réplicas. Com $df=29$ e $\alpha=0,001$, o valor crítico é 3,659.

p-valor — Probabilidade de obter um resultado tão ou mais extremo se a hipótese nula (H_0) fosse verdadeira. Quanto menor, mais forte a evidência contra H_0 .

IC 95% (Intervalo de Confiança) — Faixa que, com 95% de probabilidade, contém o valor verdadeiro do parâmetro. Calculado como $\pm 1,96 \cdot \sigma / \sqrt{n}$.

JWT (JSON Web Token) — Token de autenticação carregando dados do usuário (email, company_id...). Usado no Supabase para gerar auth.jwt() lido pelas políticas RLS.

Swarming — Prática Kanban em que toda a equipe foca em destravar um único cartão crítico, em vez de cada um manter o seu fluxo isolado.

3. Os 5 conceitos que você TEM que dominar

Se a banca cavar a fundo, ela vai cavar em um destes 5 pontos. Estude até conseguir explicar para uma pessoa que nunca viu o trabalho.

3.1 Kanban — por que importa para o seu trabalho

O Kanban surgiu na Toyota nos anos 1960 (Taiichi Ohno) como sistema de cartões físicos para sinalizar reposição de estoque just-in-time. David Anderson, em 2010, formalizou o método para gestão de trabalho intelectual em TI/serviços. As 4 práticas fundamentais são:

- Visualizar o fluxo de trabalho.
- Limitar o trabalho em progresso (WIP).
- Gerenciar o fluxo (medir Lead Time, Cycle Time, Throughput).
- Tornar as políticas de processo explícitas.

Por que isso importa para você? Porque você não está reinventando o Kanban — está respeitando seus fundamentos. O Kanban IA mantém visualização, WIP e fluxo, mas **resolve uma fraqueza estrutural**: o cartão tradicional não carrega conhecimento, ele apenas *descreve* a tarefa. Reinertsen (2009) já alertava: filas invisíveis de informação custam mais que filas de produção.

3.2 RAG — a base teórica da injeção semântica

RAG é uma arquitetura proposta por Lewis et al. em 2020 (NeurIPS) para resolver dois problemas dos LLMs:

- **Janela de contexto limitada**: o modelo não cabe a empresa inteira no prompt.
- **Alucinação**: o modelo inventa fatos quando não sabe.

A solução do RAG: **antes** de chamar o LLM, busque na base de conhecimento o que é relevante para a pergunta, e injete **apenas isso** no prompt. O LLM passa a responder com base em fontes verificáveis.

O que você melhorou? O RAG genérico faz busca por similaridade vetorial (embeddings). Isso ainda pode trazer ruído. Você adicionou uma **camada taxonômica**: as TAGS funcionam como índice semântico humano, validado pelo gestor. O resultado é um RAG *dirigido por taxonomia*, com payload 87,5% menor e zero ambiguidade.

3.3 RLS — o que protege seus clientes uns dos outros

Row Level Security é uma política aplicada **no núcleo do PostgreSQL**. Antes da consulta executar a cláusula WHERE explícita, o motor avalia se cada linha pode ser retornada para o usuário autenticado.

Exemplo do seu sistema:

```
CREATE POLICY "Knowledge base company isolation"
ON knowledge_base FOR ALL
USING (company_id IN (SELECT company_id
FROM profiles WHERE email = auth.jwt()->>'email'));
```

Por que isso é diferente de WHERE manual? Porque o WHERE manual depende do programador lembrar de colocá-lo em *toda* query. Se ele esquece em uma única chamada, vaza dado entre clientes. Com RLS, mesmo que o desenvolvedor faça `SELECT * FROM knowledge_base`, o PostgreSQL filtra automaticamente. É segurança **por construção**, não por convenção.

3.4 DES + Monte Carlo — a metodologia do seu Capítulo 5

Simulação de Eventos Discretos é a técnica clássica para modelar sistemas com filas, recursos compartilhados e variabilidade estocástica — exatamente um Kanban. Banks et al. (2010) é a referência.

Replicação Monte Carlo significa rodar o mesmo experimento simulado **múltiplas vezes** com sementes aleatórias diferentes (ou no seu caso, com seed=42 fixa para reprodutibilidade), gerando uma *distribuição* de resultados, não um número solto.

Por que 30 réplicas? Esse é o número mínimo amplamente aceito para invocar o Teorema Central do Limite (TCL): a partir de $N=30$, a média amostral tende a uma distribuição normal independentemente da distribuição subjacente, permitindo usar testes paramétricos (como o t de Student) com segurança.

3.5 Teste t pareado — sua arma contra a crítica metodológica

É o teste estatístico que compara duas medidas tomadas **do mesmo** conjunto experimental. No seu caso, em cada uma das 30 réplicas, você gera um par (Cycle Time Kanban Tradicional, Cycle Time Kanban IA). Você testa se a diferença média entre os pares é zero (H_0) ou diferente de zero (H_A).

A estatística t é calculada como:

$$t = \text{média(diferenças)} / [\text{desvio-padrão(diferenças)} / \sqrt{n}]$$

Com $df = n-1 = 29$ e $\alpha = 0,001$ (bilateral), o valor crítico de t é **3,659**. Todos os seus t-stats estouraram esse limiar (99, 109, 114, 39, 47), implicando **$p < 0,001$** — isto é, há menos de 1 chance em 1.000 de seus resultados acontecerem por acaso.

4. Arquitetura do sistema em camadas

Se a banca pedir para você desenhar a arquitetura no quadro, este é o mapa mental.

Frontend (Camada de Apresentação)

React.js 18 + Vite. Renderiza o quadro Kanban e captura o clique do operador no botão 'Solicitar Apoio da IA'. CSS puro (Vanilla CSS) para liberdade total de design — efeitos como Glassmorphism e gradientes.

Vercel Edge Network (Camada de Distribuição)

CDN distribuída globalmente. Hospeda o JS estático. Usa rewrites configurados em vercel.json para rotear chamadas /api/* como first-party, evitando bloqueadores e CORS.

Supabase (Camada de Aplicação / BaaS)

Auth (Google SSO) + API automática (PostgREST) + database. Recebe a requisição do frontend com o JWT e dispara a consulta SQL parametrizada à knowledge_base. Toda chamada passa pelas políticas RLS antes de retornar dados.

PostgreSQL (Camada de Persistência)

Banco relacional. Tabelas centrais: companies, profiles, projects, knowledge_base, tasks, ai_logs. Cada tabela sensível tem RLS habilitado com política por company_id.

Motor de IA (Camada Cognitiva)

Função no backend que recebe os POPs já filtrados, monta um prompt enxuto (~1.500 tokens) e chama a API do Google Gemini. Recebe a resposta determinística e retorna ao frontend, que renderiza o checklist no próprio cartão.

Fluxo completo, do clique ao checklist

- 1 Operador clica em 'Apoio da IA' no cartão #102 (frontend).
- 2 Frontend envia POST /api/ia-suggest com {card_id, tags, prioridade} + JWT (Vercel Edge).
- 3 Supabase recebe → resolve company_id via JWT → executa SELECT na knowledge_base.
- 4 PostgreSQL aplica RLS: retorna SÓ POPs da empresa do usuário cujas TAGS interceptam as do cartão.
- 5 Backend monta o prompt: [Metadados do cartão] + [POPs autorizados] → Gemini API.
- 6 Gemini devolve checklist passo a passo determinístico em menos de 1,5 s.
- 7 Frontend renderiza o checklist diretamente no cartão. Operador executa.

5. Roteiro narrativo da defesa

Cada slide tem uma fala-chave de 30 a 60 segundos. **Não leia o slide** — fale sobre ele. Total: 18 minutos.

S1 — Capa (15 s)

Saudação curta. Não leia o título inteiro — diga: "Vou apresentar o Mecanismo Kanban IA, uma evolução semântica do Kanban tradicional, validada estatisticamente."

S2 — Agenda (30 s)

Apenas mostre as 7 etapas. Dica: numere com os dedos.

S3 — Problema (1 min)

"Centrais de Serviços perdem entre 15% e 30% da jornada apenas procurando informação — Feldman e Sherman, IDC 2004. Esse Gargalo Cognitivo é invisível, mas custa em multas de SLA, retrabalho e turnover."

S4 — Hipótese (1 min)

Aponte os 2 cards lado a lado. "À esquerda, o cartão passivo. À direita, o cartão que injeta o checklist na própria interface. Esta é a tese central do trabalho."

S5 — Arquitetura (2 min)

Descreva as 5 camadas de baixo para cima, em 20 segundos cada: PostgreSQL → Supabase → Vercel → React → Gemini. Termine com o stat box: **1,5 s de latência**.

S6 — UML Casos de Uso (1 min)

Identifique os 3 atores e diga: "O operador é o cliente da IA. O gestor é o curador da knowledge_base. O cliente B2B alimenta o backlog."

S7 — UML Sequência (1 min)

Aponte para a nota amarela: "Aqui é onde o RLS entra. Antes da consulta retornar, o PostgreSQL já filtrou tudo que não pertence à empresa do usuário."

S8 — RLS em produção (2 min)

Mostre o SQL real. "Esta política é o que blindo 100% dos meus clientes uns dos outros. Repare em **auth.jwt()** — é o token do usuário sendo lido pelo banco, não pela aplicação."

S9 — Metodologia (1,5 min)

Os 3 cards: Modelagem (Banks 2010), Calibração (Feldman 2004), Inferência (30 réplicas + teste t). Termine: "3.000 execuções simuladas, seed 42, totalmente reprodutível."

S10-S11 — Simuladores rodando (3 min)

Recomendo demo ao vivo: abra um terminal, rode `node simulador_performance_tcc.js` e depois `python monte_carlo.py`. As capturas nos slides são fallback caso algo falhe. Aponte as métricas conforme aparecem.

S12 — Tabela de resultados (1,5 min)

Vá linha por linha. Encerre: "O valor crítico de t é 3,659. Todos os meus t-stats estão acima de 39. $P < 0,001$ em todas as métricas."

S13 — Cycle Time (1 min)

Foque no callout dourado: **-44,6%**. "De 170 para 94 minutos por cartão."

S14 — Boxplot (1 min)

Frase forte: "Mesmo a réplica mais lenta do Kanban IA é mais rápida que a réplica mais rápida do Kanban Tradicional. Não há sorte estatística aqui."

S15 — SLA e FCR (1 min)

"Quebra de SLA: 28% para zero. FCR: 53% para 95%. Estes são os números que o cliente B2B realmente vê na conta do fim do mês."

S16 — Tokens e ROI (1 min)

"Reduzi o payload do LLM em 87,5% porque envio apenas o conhecimento filtrado pela TAG. Isso traduz em economia anual potencial de R\$ 1,5 milhão para 1.000 chamados/mês."

S17 — Conclusões (1 min)

Leia os 7 itens entregues à esquerda. Mencione 2 trabalhos futuros à direita.

S18 — Obrigado (15 s)

Pausa. Sorria. "Estou à disposição para perguntas."

6. 30 perguntas prováveis da banca + respostas modelo

Estude estas como se fossem flashcards. Para cada uma, pratique falar a resposta em voz alta, sem ler. Estão agrupadas por área de ataque.

6.1 Sobre o problema e a justificativa

Q. Por que esse problema é relevante hoje?

R. Porque a popularização dos LLMs em 2023-2025 tornou viável injetar conhecimento corporativo em tempo real, mas o setor de gestão operacional ainda usa Kanban da forma de 2010. O gap entre o que a IA pode fazer e o que as ferramentas oferecem é o que justifica esta pesquisa.

Q. Esse problema não é resolvido só com uma boa wiki corporativa?

R. Não. Wiki é passiva — o operador precisa parar a tarefa, sair da tela, pesquisar, interpretar e voltar. Wait Time persiste. O Kanban IA é ativo — entrega o checklist no próprio cartão sem mudança de contexto.

Q. Como você sabe que 15-30% é um número aplicável ao Brasil?

R. É um intervalo, não um número absoluto, e foi medido pela IDC em base internacional ampla. Para um TCC, é uma âncora metodológica suficiente; em um doutorado, exigiria coleta brasileira específica — eu cito isso como limitação no §7.1.

6.2 Sobre a metodologia

Q. A sua simulação não é circular? Você calibrou os parâmetros para o resultado dar a seu favor.

R. É a crítica mais inteligente possível. Minha defesa tem 3 partes: (1) os parâmetros do Sistema A foram calibrados a partir do intervalo 15-30% de Feldman e Sherman, não inventados; (2) os parâmetros do Sistema B refletem o tempo real de leitura de um checklist gerado por LLM (2 a 5 minutos), facilmente medido; (3) o teste t pareado com $p < 0,001$ garante que mesmo com variação estocástica, a diferença é estrutural — não aleatória.

Q. Por que distribuição uniforme e não lognormal?

R. Por simplicidade e transparência. Uniforme é mais fácil de calibrar e defender. Lognormal aderiria melhor à realidade — listei isso como trabalho futuro no §7.2. Para o objetivo de comparação direcional, a uniforme é suficiente.

Q. Por que 30 réplicas e não 100 ou 1000?

R. Por causa do Teorema Central do Limite: a partir de $N=30$, a média amostral converge para uma distribuição normal, permitindo testes paramétricos como o t. Acima de 30, o ganho marginal de precisão é pequeno. Foi escolha pragmática baseada em Banks et al. (2010).

Q. Você comparou com algum sistema real?

R. Não. Esta é uma das limitações que declaro abertamente no §7.1. Estudo de caso longitudinal em operação real é o trabalho futuro #1.

Q. Seed=42 é convenção ou foi escolhido para favorecer?

R. Convenção da comunidade de ciência de dados — é a 'resposta da vida, do universo e tudo mais' do Guia do Mochileiro. Qualquer outra semente daria resultados parecidos. A escolha de seed é só para reprodutibilidade.

6.3 Sobre arquitetura e implementação

Q. Por que Supabase e não AWS RDS direto?

R. Custo total de propriedade. Supabase é PostgreSQL gerenciado com auth, API REST e realtime já integrados. Para pequenas e médias operações, equivale a anos de engenharia de plataforma sem custo. Para empresas Fortune 500, o RDS direto faz mais sentido.

Q. Por que Vanilla CSS e não Tailwind?

R. Decisão de design system. Tailwind é excelente para velocidade, mas limita o vocabulário visual. Eu precisava de efeitos de Glassmorphism e gradientes específicos. Vanilla CSS me deu controle total sem dívida de framework.

Q. Por que Gemini e não GPT-4 ou Claude?

R. Custo + acordo de processamento de dados. Gemini tem preço competitivo, suporta JSON estruturado e o Google Cloud oferece data residency. Em prod, seria trocável — a camada de IA está abstraída atrás de uma interface simples.

Q. O que acontece se a API do Gemini cair?

R. Plano de contingência: o backend tem timeout configurado. Em caso de falha, o frontend exibe os POPs brutos retornados do Supabase como fallback. A operação não trava — perde-se apenas a sumarização e o checklist guiado.

Q. Como você evita prompt injection malicioso?

R. Três camadas: (1) o conteúdo dos POPs vem da knowledge_base controlada pelo gestor — não de input livre do operador; (2) o RLS impede acesso a POPs de outras empresas; (3) o prompt template tem delimitadores explícitos. Trabalho futuro inclui testes adversariais sistemáticos.

Q. Por que RLS por email e não por user_id?

R. Escolha pragmática observada no security_hardening.sql: o JWT do Supabase carrega o email de forma consistente entre fluxos (Google SSO, link mágico, senha). Funcionalmente equivalente a user_id, mais legível em logs de auditoria.

Q. E se uma empresa tiver 10 mil POPs? A consulta não fica lenta?

R. Não. A filtragem por TAGS (array do PostgreSQL com índice GIN) é $O(\log n)$ na prática. Mesmo 100 mil registros retornam em milissegundos. O RLS aplica filtros em forma de predicado, otimizados pelo planejador.

6.4 Sobre resultados e estatística

Q. O que significa um t de 114 em termos práticos?

R. Significa que a diferença observada está 114 desvios-padrão acima do esperado por acaso. O valor crítico para $p=0,001$ é 3,659. Você poderia errar a hipótese em uma chance em centenas de milhões.

Q. Por que a Quebra de SLA do Sistema B ficou zero exato?

R. Porque o Cycle Time máximo possível no Sistema B é Wait máximo (5) + Touch máximo da alta complexidade ($200 \times 1,00$) = 205 min, abaixo dos 240 min do SLA. Estruturalmente, é impossível quebrar SLA no Sistema B sob esses parâmetros. Em condições reais com outliers, pode haver quebras esporádicas.

Q. O FCR aumentou demais (53 → 95). Não é otimista?

R. É um teto teórico decorrente das regras de FCR no simulador. A elevação reflete que com um checklist exato, complexidade média e baixa são quase 100% resolvíveis. Em produção, observaria-se algo entre 75% e 90%, ainda assim ganho significativo.

Q. Você fez ANOVA ou só teste t?

R. Só teste t pareado bilateral, pois minha comparação é de duas amostras pareadas. ANOVA seria adequada se houvesse 3 ou mais sistemas (ex: Kanban Tradicional, Kanban + IA Genérica, Kanban IA). Boa sugestão para trabalho futuro.

Q. Calculou o tamanho de efeito (Cohen's d)?

R. Não no documento atual, mas é trivial: $d = \text{média(diferenças)} / \sigma(\text{diferenças})$. Para o Cycle Time, dá aproximadamente 20+, que é classificado como 'efeito enorme' (huge). Posso incluir como anexo em uma revisão.

6.5 Sobre originalidade e impacto

Q. Isso não é apenas RAG aplicado a Kanban?

R. RAG genérico envia chunks vetorizados por similaridade. Meu trabalho usa filtragem por TAGS humanamente validadas + RLS multilocatário. É RAG dirigido por taxonomia, não por embedding. Resultado: payload 87,5% menor e zero ambiguidade semântica.

Q. Já existem produtos que fazem isso (Atlassian Intelligence, Notion AI)?

R. Esses produtos fazem sumarização e Q&A; sobre conteúdo do próprio cartão. Não fazem injeção de POPs corporativos contextualizados, com isolamento multilocatário no nível do banco. O escopo é diferente. Posso documentar a comparação em revisão futura.

Q. Qual sua contribuição em uma frase?

R. Transformei o cartão Kanban de contêiner descritivo passivo em agente contextual semântico, com isolamento multilocatário garantido por construção, validado estatisticamente via simulação Monte Carlo.

Q. E se eu quisesse implementar isso amanhã, qual a barreira?

R. Curadoria da knowledge_base. O sistema só funciona se houver POPs bem escritos e bem etiquetados com TAGS. Esse trabalho de curadoria inicial é o maior custo de adoção, não a tecnologia.

Q. Tem código aberto?

R. O simulador (Apêndice A e B) é integralmente reproduzido no TCC. O sistema completo está em desenvolvimento contínuo no repositório próprio. Estou aberto a publicar uma versão demo após a defesa, se a banca recomendar.

6.6 Perguntas-armadilha (responda com calma)

Q. Você usou IA para escrever este TCC?

R. Usei IA como ferramenta de apoio à redação, à mesma escala em que usaria um corretor gramatical ou um colega revisor — mas o conteúdo técnico, a hipótese, a modelagem do simulador, a interpretação dos resultados e as decisões arquiteturais são meus. Posso defender cada linha do trabalho oralmente.

Q. Por que não rodou em ambiente real?

R. Por restrição de prazo e de acesso a uma operação cliente disposta a participar. Está declarado como limitação no §7.1 e como trabalho futuro prioritário no §7.2.

Q. E o impacto humano? Os operadores não vão ser substituídos pela IA?

R. Pelo contrário. A IA elimina o tempo de busca, não o trabalho. O operador continua sendo o executor — mas com menos fadiga decisória, mais autonomia e menos escalações. A pesquisa de Choo (2003) sustenta que a entrega oportuna do conhecimento eleva, não substitui, a tomada de decisão humana.

7. Armadilhas da banca e como escapar delas

7.1 'Por que você não fez X?'

Banca sempre acha que faltou algo. Estratégia: **não se defenda — concorde, contextualize, redirecione**. Exemplo: *"Excelente sugestão, professor. Isso seria de fato o próximo passo natural. No escopo deste TCC, optei por X para manter rigor metodológico em [aspecto], mas listei sua sugestão como trabalho futuro no §7.2."*

7.2 'Esse resultado parece bom demais'

Esperem essa. A resposta: *"Concordo que os números são expressivos. Eles refletem uma simulação controlada, calibrada a partir da literatura. O ganho relativo é o que importa, não os valores absolutos. Em ambiente real, o ganho seria menor — talvez 30-40% no Cycle Time em vez de 44% — mas direcionalmente robusto."*

7.3 'Qual o limite ético?'

Resposta pronta: *"Há três limites éticos claros: (1) o conteúdo da knowledge_base é curado por humanos, não gerado pelo LLM; (2) o operador final mantém autonomia para divergir do checklist quando o contexto pedir; (3) toda decisão sugerida pela IA é registrada em ai_logs para auditoria. A IA é assistente, não decisora."*

7.4 'E se a banca pegar pesado em estatística?'

Mantra: **defina, demonstre, declare limite**. Defina o que mediu (Cycle Time médio). Demonstre como mediu (30 réplicas × 100 cartões, t pareado df=29). Declare limite (intervalo de confiança ±IC95).

7.5 'Não entendi sua arquitetura'

Pegue caneta. Vá ao quadro. Desenhe as 5 camadas verticais e mostre as setas: operador → React → Vercel → Supabase → PostgreSQL (com RLS marcado) → Gemini. Isso enche os olhos.

7.6 'O que você faria de diferente?'

Resposta forte: *"Substituiria a distribuição uniforme do Touch Time por lognormal, instrumentaria uma operação real para coletar tempos verdadeiros e adicionaria testes adversariais de prompt injection. Já está tudo no §7.2 como trabalho futuro."* Você está se autoavaliando antes da banca — isso desarma críticas.

8. Cartão de bolso — decore na véspera

Imprima esta página e leve para a defesa. Use só se travar.

Os números que TODO TCC tem que ter na ponta da língua

Métrica	Kanban	Kanban IA	Δ	t (df=29)
Wait Time	Kanban: 47,5 $\pm$ 2,4 min	Kanban IA: 3,5 $\pm$ 0,1 min	-92,6%	t = 99,7
Touch Time	123,1 $\pm$ 5,3 min	91,0 $\pm$ 4,1 min	-26,1%	t = 109,8
Cycle Time	170,6 $\pm$ 7,4 min	94,5 $\pm$ 4,0 min	-44,6%	t = 114,7
Quebra SLA	28,3 $\pm$ 3,9%	0,0%	-100%	t = 39,3
FCR	53,4 $\pm$ 4,3%	95,3 $\pm$ 2,3%	+41,9 p.p.	t = 47,3

Outras métricas críticas

- Amostra: 30 réplicas $\times$ 100 cartões = 3.000 execuções simuladas
- Seed: 42 (reprodutível)
- Valor crítico t (df=29, $\alpha=0,001$ bilateral): **3,659**
- SLA contratual: 240 minutos (4 horas)
- Payload LLM: 12.000 $\rightarrow$ 1.500 tokens (-87,5%)
- Latência IA: < 1,5 segundos
- Custo hora técnica: R\$ 50,00
- Horas salvas / lote 100 cartões: 127,8 horas
- ROI anual estimado (1.000 chamados/mês): ~R\$ 1,5 milhão

Autores que VOCÊ TEM QUE CITAR de cabeça

- **Anderson (2010)** — Kanban formalizado para TI; 4 práticas centrais
- **Reinertsen (2009)** — Cost of Delay, filas invisíveis de informação
- **Feldman & Sherman (IDC, 2004)** — 15-30% do tempo procurando informação
- **Choo (2003)** — Conhecimento contextualizado eleva decisão
- **Lewis et al. (NeurIPS, 2020)** — RAG seminal
- **Min et al. (EMNLP, 2022)** — Importância da delimitação de contexto
- **Banks et al. (2010)** — DES e replicação Monte Carlo
- **Chong & Carraro (2006)** — Estratégias multi-tenant SaaS

9. Checklist do dia D

Na véspera (D-1)

- Rer o cap. 1 (Resumo executivo) e cap. 8 (Cartão de bolso) em voz alta 3 vezes
- Ensaiar a defesa cronometrada — 1 vez do início ao fim
- Carregar PPTX em pendrive E enviar para o e-mail (backup duplo)
- Imprimir 4 cópias da monografia: 1 para você, 3 para a banca
- Testar projetor / cabos HDMI / adaptador USB-C
- Preparar a roupa
- Dormir 8 horas — não estude depois das 22h

Na manhã do dia (D)

- Café da manhã reforçado (proteína + carboidrato lento)
- Hidratação: 1 garrafa de água
- Chegar 40 minutos antes do horário marcado
- Ir ao banheiro 10 minutos antes
- Respirar fundo 5 vezes antes de entrar (técnica 4-7-8)
- Levar: notebook + carregador + pendrive + cópia impressa + caneta + água + cartão de bolso

Durante a apresentação

- Cumprimentar os 3 examinadores nominalmente, se souber
- Falar com voz firme e em ritmo médio — pausa entre frases
- Não ler os slides — fale SOBRE eles
- Olhar para os 3 examinadores em rotação, não só para o orientador
- Se travar, beba água, respire e siga
- Se a demo ao vivo travar, vá direto ao screenshot no slide
- Cronometrar mentalmente: aos 9 minutos você deve estar no slide 9

Durante a arguição (perguntas)

- Ouça a pergunta inteira — não interrompa
- Repita a pergunta com suas palavras (te dá 3 segundos para pensar)
- Comece a resposta com "Boa pergunta, professor(a)" — desarma o tom
- Se não souber, diga: "Não tenho a resposta neste momento, mas a investigarei. É um excelente apontamento."
- Nunca diga "eu não sei" seco — sempre conclua com plano
- Ao final, agradeça nominalmente cada examinador

Fim

Você fez o trabalho. Você fez 3.000 simulações estatísticas. Você tem 654 KB de monografia, 18 slides polidos, código real rodando em produção, RLS implementado e testado.

A banca não está lá para te derrubar. Está lá para garantir que você sabe o que escreveu.

E você sabe. Boa defesa.